NutriPulse - Démarche du projet

Estimer le niveau de risque de malnutrition des enfants de 0 à 59 mois à partir de simples réponses de questionnaire, puis classer les ménages en trois niveaux de risque pour décider **qui visiter en premier**.

Ce document décrit la **démarche** : quoi faire, dans quel ordre, et pourquoi. Il ne contient pas de code.

Sommaire

1. Contexte et objectif
2. Architecture générale : de la donnée au niveau de risque
3. Partie 1 - Le nettoyage
4. Partie 2 - L'analyse exploratoire
5. Partie 3 - La modélisation (machine learning)
6. Du modèle à l'outil : probabilités, niveaux de risque, ménages, SHAP
7. Pièges à éviter
8. Livrables et ordre d'exécution
9. L'interface Gradio

---

1. Contexte et objectif

Le problème

Mesurer la taille et le poids de **chaque** enfant est lent et coûteux. Les équipes de terrain (ONG, agents de santé) ont des moyens limités : elles ne peuvent pas tout mesurer partout en même temps. Remplir un questionnaire sur le ménage est, au contraire, rapide.

L'idée

Utiliser des réponses de questionnaire (région, âge de l'enfant, toilettes, électricité, instruction de la mère...) pour estimer, **sans balance ni toise**, le risque de malnutrition de chaque enfant, puis du ménage.

Les deux problèmes suivis

Problème	Définition	Nature
Retard de croissance (stunting)	L'enfant est trop petit pour son âge	Chronique
Émaciation (wasting)	L'enfant est trop maigre pour sa taille	Aigu

Les deux problèmes sont presque indépendants et ont des facteurs différents : on construit **un modèle pour chacun**.

Les données

Enquête MICS6 Togo 2017. Trois fichiers suffisent :

- `ch.sav` : les enfants de moins de 5 ans, avec leurs mesures et z-scores ;
- `hh.sav` : les ménages ;
- `hl.sav` : les membres des ménages.

Après filtrage des mesures absentes ou implausibles, on travaille sur environ **4 900 enfants** : un jeu de données **petit** (quelques milliers de lignes) et **tabulaire** (une dizaine de variables, surtout catégorielles). Ce détail guide plusieurs choix de modèles plus loin.

Ce que l'outil est, et n'est pas

> **L'outil classe, il ne diagnostique pas.** Un ménage "à risque élevé" est un ménage à visiter en premier, pas un ménage où l'on sait qu'un enfant est malade. Il ne remplace jamais la mesure.

---

2. Architecture générale : de la donnée au niveau de risque

Le but en une phrase

Créer deux colonnes cibles (**stunt** et **waste**), apprendre à en déduire une **probabilité**, **découper cette probabilité** en trois niveaux de risque pour classer les ménages, et **expliquer** chaque classement avec SHAP.

Le trajet complet

```
DONNÉES BRUTES (ch, hh, hl)
          |
```

```
         v
[1] NETTOYAGE : fusion, filtre, cibles, codes, types
         |
         v
FICHIER PROPRE : 14 variables d'entrée + 2 cibles (stunt, waste)
         |
         v
[2] EXPLORATION : tendances, corrélations avec la cible
         |
         v
[3] MODÉLISATION : un modèle par cible
         |
         v
PROBABILITÉ pour chaque enfant (une pour stunt, une pour waste)
         |
         v
DÉCOUPAGE de la probabilité : faible / moyen / élevé
         |
         v
REGROUPEMENT par ménage : niveau de risque du ménage
         |
         v
EXPLICATION (SHAP) : pourquoi ce niveau ?
```

Les trois notions à ne pas confondre

Notion	Colonnes	Valeurs	Rôle
Réalité mesurée	`stunt_niveau`, `waste_niveau`	normal, modéré, sévère (0, 1, 2)	Ce que la balance et la toise ont révélé. Sert à **décrire et vérifier**, pas à entraîner.
Cible d'entraînement	`stunt`, `waste`	0 ou 1	Ce que le modèle apprend à reconnaître : "cet enfant ressemble-t-il à ceux qui sont touchés ?"
Sortie du modèle	probabilité, puis niveau de risque	0 à 1, puis faible / moyen / élevé	Ce que l'agent **voit**. Sert à **prioriser**.

> **Ce que l'on veut obtenir au final, c'est la probabilité.** C'est à nous de décider ensuite comment la découper en niveaux de risque, selon la capacité de prise en charge.

Pourquoi ne pas entraîner directement sur normal / modéré / sévère ?

- Les cas **sévères** sont trop rares (surtout en émaciation) : le modèle ne peut rien apprendre de stable.
- Distinguer le modéré du sévère à partir d'un questionnaire de ménage est trop ambitieux : le sévère dépend de facteurs que le questionnaire ne voit pas (maladie en cours, alimentation précise).
- Une probabilité donne un **classement fin**, que l'on peut découper comme on veut. Un classement en trois classes appris directement est plus fragile.

> **Niveau de risque** (faible, moyen, élevé) et **gravité mesurée** (normal, modéré, sévère) sont deux choses différentes. Il ne faut pas les mélanger à l'écran.

---

3. Partie 1 - Le nettoyage

Livrable : un notebook `nettoyage.ipynb` qui produit un seul fichier propre, `nutripulse_clean.parquet` .

Objectif : transformer les fichiers bruts en un tableau propre, sans erreur, où chaque ligne est un enfant et chaque colonne a un sens clair et un type correct.

Les règles de base

- Les fichiers bruts (`data/raw`) ne sont **jamais modifiés**.
- Le fichier propre est produit **uniquement** par le notebook de nettoyage. Si une règle change, on corrige le notebook, on le relance, le fichier est régénéré. On ne retouche **jamais** le fichier propre à la main.
- Le nettoyage ne fait **ni imputation, ni encodage, ni mise à l'échelle**. Tout ce qui "apprend" sur les données se fera plus tard, dans un pipeline ajusté sur l'entraînement seulement, pour éviter la **fuite de données**.
- Chaque décision est **documentée** dans le notebook (cellules explicatives).

Les étapes, dans l'ordre

Étape 1 - Lire les fichiers en gardant les codes

Lire `ch` , `hh` et `hl` en conservant les **codes numériques** (pas les libellés texte), et garder aussi les métadonnées.
Pourquoi : on doit voir les codes spéciaux (7, 8, 9, 96, 97...) pour décider nous-mêmes, variable par variable, s'il s'agit d'un manquant ou d'une vraie réponse.

Étape 2 - Relire les libellés avant toute décision

Pour chaque variable, lire le sens de chaque code dans les métadonnées.
Pourquoi : un même code n'a pas le même sens partout. Par exemple, 97 est "incohérent" pour la taille du ménage, mais "pas de repas préparé" (une vraie réponse) pour le type de cuisinière. Ne jamais deviner.

Étape 3 - Vérifier l'unicité des identifiants
Un enfant se reconnaît par (grappe, ménage, ligne). Un ménage par (grappe, ménage). Une personne par (grappe, ménage, ligne). Vérifier qu'aucun n'est en double.
Pourquoi : un doublon de clé ferait **multiplier les lignes** lors de la fusion, sans qu'on le voie.

Étape 4 - Sélectionner les colonnes utiles et les renommer
Garder uniquement les colonnes nécessaires dans chaque fichier, avec des noms lisibles en minuscules.
Pourquoi : les fichiers ont des centaines de colonnes, et certaines portent le même nom d'un fichier à l'autre. Sélectionner et renommer **avant** de fusionner évite les doublons et la confusion.

Étape 5 - Fusionner les trois fichiers
Partir de la table des enfants et lui ajouter :

1. le **sexe de l'enfant**, en le cherchant dans `hl` via le numéro de ligne de l'enfant ;
2. les **caractéristiques du ménage**, en cherchant dans `hh` via (grappe, ménage) ;
3. l'**âge de la personne qui s'occupe de l'enfant**, en cherchant dans `hl` une **autre** ligne (celle de la gardienne).

Pourquoi : le questionnaire est réparti en trois fichiers, et l'information utile à un enfant se trouve à trois endroits. Toutes les jointures conservent **tous les enfants** : on préfère voir apparaître une case vide plutôt que perdre un enfant sans le savoir.
Contrôles : le nombre de lignes avant et après doit être identique, aucun doublon, et les copies de contrôle (sexe et région déjà présents dans `ch`) doivent concorder à 100 % avec ce que la jointure a apporté.

Étape 6 - Filtrer l'échantillon
Retirer les enfants **sans mesure** et ceux dont la mesure est jugée **implausible** par l'enquête (drapeaux de plausibilité).
Pourquoi : la cible est calculée à partir des mesures. Sans mesure fiable, il n'y a pas de cible. Les mesures implausibles sont codées avec une valeur factice (99.99) qui fausserait tout.

Étape 7 - Construire les cibles
Utiliser les **z-scores OMS** (jamais les versions NCHS) et les comparer aux seuils de l'OMS :

	Retard de croissance (taille pour	**Émaciation (poids pour la**

Z-score	l'âge)	taille)
supérieur ou égal à -2	normal	normal
entre -3 et -2	modéré	modérée
inférieur à -3	sévère	sévère

Créer ces colonnes :

- **`stunt`** : 1 si le z-score de taille pour l'âge est inférieur à -2, sinon 0 ;
- **`waste`** : 1 si le z-score de poids pour la taille est inférieur à -2, sinon 0 ;
- **`stunt_niveau`** et **`waste_niveau`** : 0 normal, 1 modéré, 2 sévère (pour décrire) ;
- conserver les **z-scores** pour les graphiques et les audits.

Pourquoi : `stunt` et `waste` sont les deux cibles des deux modèles. Les niveaux servent à décrire la réalité. Les z-scores **ne doivent jamais** servir d'entrée : ils sont la réponse elle-même.

Étape 8 - Nettoyer variable par variable
Pour chacune des 14 variables d'entrée (voir tableau plus bas), appliquer les règles :

- les codes "incohérent", "ne sait pas", "non réponse" deviennent des **cases vides** ;
- les codes trop détaillés sont **regroupés** (cuisinière, toilettes, lavage des mains, source d'eau) ;
- les questions oui/non sont recodées en **1 / 0** ;
- le sexe est recodé en une variable binaire claire (1 = fille) ;
- la taille du ménage est **plafonnée au 99e percentile** ;
- l'âge de la personne qui garde l'enfant est contrôlé après la jointure (valeurs extrêmes).

Pourquoi : un code spécial laissé comme un nombre serait lu comme une vraie quantité par le modèle. Les regroupements évitent des modalités minuscules qui n'apporteraient que du bruit. Le plafonnement limite l'influence de quelques très grands ménages.

Étape 9 - Définir les groupes et les poids
Conserver :

- la **grappe** de l'enfant, qui servira de **groupe** pour découper les données en validation croisée ;
- l'**identifiant du ménage**, pour regrouper les enfants d'un même ménage à la fin ;
- le **poids d'échantillonnage**, uniquement pour les chiffres nationaux.

Pourquoi : les enfants d'une même grappe se ressemblent beaucoup. Si on découpait les données au hasard, des enfants presque identiques se retrouveraient à la fois en entraînement et en test, et les performances seraient **gonflées**. Il faut découper **par grappe entière**.

Étape 10 - Mettre de côté les colonnes d'audit
Conserver le **milieu** (urbain ou rural), le **quintile de richesse** et l'**ethnie**, mais **jamais comme entrées**.
Pourquoi : elles servent uniquement à vérifier plus tard que l'outil n'est pas moins performant pour un groupe donné (équité). L'ethnie est une variable sensible.

Étape 11 - Fixer les types
Distinguer :

Famille	Exemples	Stockage
Catégorielle **nominale** (sans ordre)	région, type de cuisinière	catégorie
Catégorielle **ordinale** (ordre naturel)	instruction de la mère, électricité, toilettes, lavage des mains	catégorie ordonnée
Binaire	sexe, acte de naissance, eau améliorée, animaux, téléphone	petit entier (entier nullable s'il reste des manquants)
Numérique	âge de l'enfant, âge de la gardienne, taille du ménage	entier

Pourquoi : dans MICS, presque tout est stocké en nombres, même ce qui n'est pas une quantité. Un code n'est pas un nombre : si la région restait numérique, un modèle croirait que la région 4 vaut "deux fois" la région 2.

Étape 12 - Contrôles automatiques
Faire échouer le nettoyage si l'une de ces conditions n'est pas remplie : nombre de lignes attendu, aucun doublon, binaires uniquement 0 ou 1, catégories dans les modalités prévues, **manquants exactement ceux attendus**, aucune colonne de fuite parmi les entrées, cohérence entre cibles binaires et niveaux.
Pourquoi : si une règle est cassée plus tard, on le sait immédiatement au lieu de découvrir des résultats bizarres des semaines après.

Étape 13 - Exporter et relire
Écrire **un seul** fichier propre au format **parquet**, puis le relire et le comparer.

Pourquoi : le parquet conserve les types (catégories, ordre, entiers nullables), contrairement au CSV. La relecture prouve que ce qui est écrit est identique à ce qu'on voulait écrire.

Les 14 variables d'entrée

Communes aux deux modèles (6)

Variable	Contenu	Règle de nettoyage	Type
`age_mois`	Âge de l'enfant en mois (0 à 59)	Aucun code spécial	Numérique
`region`	Région de résidence (7)	Remplacer les codes par les noms	Nominale
`edu_mere`	Instruction de la mère	"Ne sait pas" en case vide	Ordinale
`electricite`	Électricité dans le ménage	Code "incohérent" en case vide	Ordinale
`cuisiniere`	Type de cuisinière	Regrouper en 4 modalités ; le code 97 est une vraie réponse ici	Nominale
`toilettes`	Type de toilettes	Regrouper en 4 modalités	Ordinale

Propres au retard de croissance (4)

Variable	Contenu	Règle de nettoyage	Type
`sexe_f`	Sexe de l'enfant	1 si fille, 0 sinon	Binaire
`acte_naissance`	Acte de naissance	"Ne sait pas" en case vide ; 1 si oui, 0 si non	Binaire nullable
`eau_amelioree`	Source d'eau de boisson	1 si source améliorée, 0 sinon	Binaire
`animaux`	Animaux d'élevage	Oui/non en 1/0	Binaire

Propres à l'émaciation (4)

Variable	Contenu	Règle de nettoyage	Type

`age_gardien`	Âge de la personne qui garde l'enfant	Contrôler les extrêmes après la jointure	Numérique
`taille_menage`	Nombre de personnes du ménage	Plafonner au 99e percentile	Numérique
`lavage_mains`	Lieu de lavage des mains observé	Regrouper en 3 modalités ; fusionner "refus" avec "aucun lieu"	Ordinale
`telephone`	Téléphone portable dans le ménage	Oui/non en 1/0	Binaire

Variables à ne jamais utiliser comme entrées

- **Fuites** : tout ce qui vient des mesures (poids, taille, z-scores, indicateurs de plausibilité, IMC...).
- **Sensibles** : ethnie et religion (l'ethnie reste seulement en colonne d'audit).
- **Redondantes** : indice de richesse (calculé après coup, et corrélé aux équipements déjà retenus), milieu urbain ou rural (corrélé à la région), type d'éclairage (corrélé à l'électricité), matériaux du logement.
- **À couverture insuffisante** : alimentation, vaccination, handicap, moustiquaires (moins de 90 % des enfants concernés).
- **Symptômes récents** : diarrhée, fièvre, toux (risque de causalité inversée : l'enfant malnutri tombe plus souvent malade).

---

4. Partie 2 - L'analyse exploratoire

Livrable : un premier notebook d'analyse, `analyse_1_exploration.ipynb`.

Objectif : comprendre les données **avant** de modéliser, voir les tendances et les liens avec les cibles, et se faire une idée réaliste de ce que le projet final peut donner.

Règle : ce notebook ne lit que le fichier propre.

Les analyses à faire, dans l'ordre

1. Vérifier le fichier propre

Lister les types et le nombre de valeurs distinctes par colonne ; compter les manquants. Toute colonne numérique avec moins de 10 valeurs dont les codes sont des étiquettes est suspecte.

Pourquoi : repartir sur de bonnes bases, et détecter une erreur de typage avant qu'elle ne fausse l'analyse.

2. Décrire les deux cibles
Prévalence du retard de croissance et de l'émaciation, répartition par niveau (normal, modéré, sévère), croisement des deux cibles.
Pourquoi : connaître le **déséquilibre** des classes (l'émaciation est rare) conditionne le choix des métriques et des modèles. Le faible lien entre les deux cibles justifie de faire **deux modèles**.

3. Distinguer prévalence non pondérée et pondérée
Calculer les prévalences avec et sans le poids d'échantillonnage.
Pourquoi : les chiffres non pondérés décrivent l'**échantillon**, pas la population togolaise. Pour toute estimation nationale, il faut utiliser le poids.

4. Décrire chaque variable d'entrée
Distribution de chacune des 14 variables (effectifs, histogrammes).
Pourquoi : repérer les modalités très rares, les asymétries, les valeurs étranges.

5. Prévalence de chaque cible selon chaque variable
Pour chaque variable, calculer la part d'enfants touchés dans chaque modalité (région, instruction de la mère, toilettes…), avec les effectifs.
Pourquoi : c'est l'analyse la plus parlante. Elle montre quelles variables séparent vraiment les enfants touchés des autres. Garder en tête les effectifs : un pourcentage calculé sur 15 enfants n'est pas fiable.

6. Étudier la courbe de l'âge
Prévalence de chaque cible par tranche d'âge (0-5, 6-11, 12-23, 24-35, 36-47, 48-59 mois).
Pourquoi : l'âge est la variable la plus importante, et sa **forme** diffère selon la cible (le retard monte puis plafonne ; l'émaciation culmine tôt puis retombe). Cela dit si le modèle a besoin de gérer une relation non linéaire.

7. Étudier les variables numériques
Âge de la gardienne et taille du ménage selon la cible (boîtes à moustaches, taux par tranche).

8. Mesurer les liens entre variables d'entrée
Corrélations entre variables : **V de Cramér** pour les catégorielles, corrélation de rang pour les ordinales et numériques.
Pourquoi : repérer les **redondances** (région, électricité, toilettes sont liées). Cela explique plus tard pourquoi l'importance se répartit entre variables proches.

9. Mesurer les liens avec la cible

Pour chaque variable : V de Cramér ou test du khi-deux pour les catégorielles, test de comparaison de distributions pour les numériques, information mutuelle. Classer les variables.
Pourquoi : un premier classement de l'utilité des variables. À lire comme des **associations**, pas des causes.

10. Explorer quelques interactions
Par exemple âge et région, instruction de la mère et région, taille du ménage et pauvreté.
Pourquoi : si un effet n'existe que dans certaines régions, les modèles en arbres le capteront mieux qu'un modèle linéaire simple.

11. Mesurer l'effet de grappe
Voir à quel point les enfants d'une même grappe se ressemblent (variation de la prévalence entre grappes).
Pourquoi : si les grappes diffèrent beaucoup, c'est la preuve qu'il faut découper **par grappe** en validation, sinon les performances seront surestimées.

12. Cartographier les manquants
Quelles colonnes ont des cases vides, combien, et sont-elles liées à autre chose ?
Pourquoi : décider de la stratégie d'imputation du pipeline.

13. Préparer l'audit d'équité
Prévalence de chaque cible selon le milieu, le quintile de richesse et l'ethnie.
Pourquoi : connaître à l'avance les écarts réels, pour savoir ensuite si le modèle les reproduit ou les amplifie.

14. Faire un premier test rapide, très simple
Entraîner un modèle minimal (par exemple l'âge et le sexe seuls, puis un modèle linéaire simple) avec un découpage par grappe, et regarder les premiers niveaux de risque obtenus.
Pourquoi : fixer le **plancher** de performance à battre, et se faire une idée du résultat final (probabilité, puis niveaux) avant de se lancer dans la grande modélisation.

Ce qu'on doit pouvoir dire à la fin de cette partie

- quelles variables semblent les plus liées à chaque cible ;
- quelles relations sont non linéaires ;
- quelles variables sont redondantes ;
- quel ordre de grandeur de performance est réaliste.

> **Ordre de grandeur attendu** : un signal **réel mais modeste** (un AUC autour de 0,65, soit un classement meilleur que le hasard mais loin d'être parfait). Si l'on trouve beaucoup plus, il faut **suspecter une fuite de données** avant de se réjouir.

---

5. Partie 3 - La modélisation (machine learning)

Livrable : un second notebook d'analyse, `analyse_2_modelisation.ipynb`.

Objectif : construire, pour chaque cible, un modèle qui donne une **probabilité** fiable pour classer les enfants.

5.1 Poser le problème

- **Tâche** : classification binaire, **deux fois** (une pour `stunt`, une pour `waste`).
- **Sortie voulue** : une **probabilité** entre 0 et 1 pour chaque enfant (pas une étiquette 0 ou 1).
- **Entrées** : les 10 variables de chaque modèle (6 communes + 4 propres).
- **Jamais en entrée** : z-scores, niveaux, cibles, colonnes d'audit, identifiants, poids.

5.2 Découper les données

1. **Mettre de côté un jeu de test final** (par exemple 20 % des **grappes**), qu'on ne touche **pas** avant la toute fin.
2. Sur le reste, utiliser une **validation croisée en 5 plis groupée par grappe**, **stratifiée** sur la cible.
3. **Répéter** avec des découpages différents.

Pourquoi :

- **groupée par grappe** : pour que des enfants d'un même quartier ne soient pas à la fois en entraînement et en test (sinon, performances gonflées) ;
- **stratifiée** : surtout pour l'émaciation, où les cas sont rares, pour que chaque pli en contienne assez ;
- **répétée** : avec peu de données, un seul découpage donne un résultat instable. Les écarts d'environ 0,005 d'AUC entre variantes sont dans le **bruit** de la validation.
- **jeu de test final** : seul moyen d'avoir une mesure honnête, non influencée par tous les essais de réglage.

5.3 Le pipeline et le ColumnTransformer

Oui, il faut un pipeline avec un ColumnTransformer.

Un **pipeline** enchaîne le prétraitement et le modèle en un seul objet. Il est **ajusté uniquement sur les données d'entraînement de chaque pli**, puis appliqué au pli de validation.

Pourquoi : c'est la protection principale contre la **fuite de données**. Si l'on calculait une

moyenne, une catégorie la plus fréquente ou une échelle sur **toutes** les données avant de découper, l'information du test fuirait dans l'entraînement.

Le **ColumnTransformer** applique un traitement **différent selon la famille de colonne** :

Famille	Colonnes	Traitement
Numérique	âge de l'enfant, âge de la gardienne, taille du ménage	Imputation par la médiane ; mise à l'échelle **seulement pour les modèles linéaires**
Nominale	région, cuisinière	Imputation par la modalité la plus fréquente ; **encodage one-hot** (regrouper les modalités rares, ignorer les modalités inconnues)
Ordinale	instruction de la mère, électricité, toilettes, lavage des mains	Imputation par la modalité la plus fréquente ; **encodage ordinal** avec l'ordre explicite (0, 1, 2...)
Binaire	sexe, eau, animaux, téléphone, acte de naissance	Imputation par la modalité la plus fréquente (pour l'acte de naissance, ajouter éventuellement un indicateur de valeur manquante)

5.4 Faut-il normaliser ou standardiser ?

Modèle	Standardisation nécessaire ?	Pourquoi
Régression logistique	**Oui**	La régularisation pénalise les coefficients : si les variables n'ont pas la même échelle, la pénalité est injuste
Forêt aléatoire	Non	Les arbres comparent des seuils, l'échelle ne change rien
Gradient boosting	Non	Même raison

On a donc **deux variantes de pipeline** : avec mise à l'échelle pour le modèle linéaire, sans pour les modèles à arbres. Pour le modèle linéaire, prévoir aussi de capter la **non-linéarité de l'âge** (tranches d'âge ou fonctions splines).

5.5 Le déséquilibre des classes

Le retard de croissance concerne environ un enfant sur quatre ; l'émaciation environ un sur

dix-sept.

- Tester **avec et sans pondération** de la classe rare, et garder ce qui donne la meilleure mesure en validation.
- **Éviter le sur-échantillonnage artificiel** (par exemple SMOTE) : avec peu de données bruitées, il crée de faux exemples, et il fausse les probabilités. S'il était utilisé, il devrait l'être **à l'intérieur** de chaque pli seulement.

Pourquoi : le déséquilibre rend la précision globale (accuracy) **trompeuse** : pour l'émaciation, répondre "personne n'est touché" donnerait 94 % de bonnes réponses sans rien détecter.

5.6 Les métriques

On veut un **classement** (priorisation) et une **probabilité**. Les métriques doivent mesurer ça, pas la justesse d'une étiquette.

Métrique	Ce qu'elle mesure	Pourquoi la choisir
AUC-ROC	La capacité à classer un enfant touché au-dessus d'un enfant non touché	**Métrique principale** : indépendante de tout seuil, adaptée à un objectif de classement
PR-AUC (précision moyenne)	Le compromis précision / rappel	**Indispensable pour l'émaciation** (classe rare) : l'AUC-ROC peut paraître correcte alors que la précision est mauvaise. À comparer à la prévalence, qui est le niveau du hasard
Prévalence réelle par niveau de risque	La part d'enfants réellement touchés dans faible / moyen / élevé	**Métrique d'usage** : elle doit **monter** d'un niveau à l'autre, sinon le découpage est inutile
Capture dans le niveau élevé (courbe de gain)	Quelle part de tous les cas se trouve dans les 20 % les plus à risque	Répond à la vraie question de l'ONG : "si je visite 20 % des enfants, combien de cas je touche ?"
Brier score et **courbe de**	Si la probabilité annoncée correspond à la	Nécessaire si l'on veut **interpréter** la probabilité comme un risque

calibration	fréquence réelle	
Log-loss	Qualité des probabilités	Utile pour comparer les modèles et pour le réglage
Précision, rappel, F1	Qualité d'une **étiquette** à un seuil donné	Secondaires : à regarder seulement **au seuil choisi**

À ne pas utiliser comme métrique principale : l'accuracy (trompeuse avec des classes déséquilibrées).

Toujours rapporter la moyenne et la **dispersion** sur les plis répétés, pas un chiffre unique. Rapporter aussi la performance **par sous-groupe** (milieu, quintile, ethnie) pour l'audit d'équité.

5.7 Les modèles à comparer

Le jeu de données est **petit** (environ 4 900 lignes), avec **peu de variables** (10 par modèle), surtout **catégorielles**, et un signal **modeste**. Cela oriente le choix : on cherche des modèles qui **ne sur-apprennent pas** et qui donnent de **bonnes probabilités**.

Modèle 1 - Régression logistique régularisée (le modèle de référence)

- *Pourquoi :* simple, rapide, stable avec peu de données, donne naturellement de **bonnes probabilités**, et ses coefficients s'**interprètent** directement.
- *Rôle :* c'est le **plancher** à battre. Si un modèle plus complexe ne fait pas mieux, on garde le simple.
- *Limite :* elle ne capte pas seule les interactions ni les relations non linéaires (il faut les lui préparer).

Modèle 2 - Forêt aléatoire (Random Forest)

- *Pourquoi :* robuste, peu sensible aux réglages, capte **sans effort** les non-linéarités et les interactions (par exemple l'âge selon la région), supporte bien un petit échantillon et du bruit.
- *Limite :* les probabilités sont souvent moins bien calibrées (à vérifier et corriger si besoin).

Modèle 3 - Gradient boosting
(par exemple `HistGradientBoosting` de scikit-learn, ou LightGBM, XGBoost)

- *Pourquoi :* c'est en général le **meilleur compromis pour les données tabulaires**. Il capte les interactions, gère les valeurs manquantes et accepte les variables catégorielles. Il fonctionne bien avec des milliers de lignes.

- *Limite :* il **sur-apprend facilement** avec peu de données et un signal faible. Il faut le **brider** : arbres peu profonds, apprentissage lent, régularisation forte, arrêt précoce.

Modèle 4 (optionnel) - CatBoost

- *Pourquoi :* conçu pour les variables **catégorielles** (ici majoritaires), avec une bonne résistance au sur-apprentissage sur petits jeux de données et peu de réglages.

Ce qu'on écarte, et pourquoi

- **Réseaux de neurones** : trop peu de données pour un avantage réel, et plus difficiles à expliquer.
- **SVM** : peu naturels pour produire des probabilités, sans avantage ici.
- **k plus proches voisins** : sensibles au bruit et aux variables catégorielles.

Comment choisir

- Comparer les modèles **avec le même découpage** et les mêmes métriques.
- Régler **légèrement** (une petite grille ou une recherche courte), en restant en validation croisée groupée : un réglage excessif sur un petit jeu **sur-ajuste la validation elle-même**.
- Si deux modèles sont à égalité (écart dans le bruit, environ 0,005 d'AUC), **garder le plus simple et le mieux calibré**.

5.8 Obtenir les probabilités "honnêtes"

1. Produire, pour **chaque enfant**, la probabilité prédite **hors apprentissage** (c'est-à-dire par le modèle qui ne l'a pas vu à l'entraînement) : ce sont les probabilités "out-of-fold".
2. Vérifier la **calibration** : la probabilité annoncée correspond-elle à la fréquence réelle ?
3. Si besoin (surtout avec la pondération de la classe rare, qui **gonfle** les probabilités), **recalibrer** (par exemple par la méthode sigmoïde, plus adaptée aux petits effectifs que l'isotonique).

Pourquoi : ce sont ces probabilités honnêtes qui servent à **découper** en niveaux de risque. Utiliser les prédictions sur les données d'entraînement donnerait des découpages trop optimistes.

> Si l'on ne calibre pas, la sortie reste un **score de classement fiable pour comparer des enfants entre eux**, mais ce n'est pas une "chance d'être malnutri" à afficher telle quelle.

---

6. Du modèle à l'outil : probabilités, niveaux de risque,

ménages, SHAP

6.1 Découper la probabilité en niveaux de risque

C'est **à nous de décider** comment découper. Le principe est simple : **plus la probabilité est haute, plus le niveau est élevé**.

Point de départ proposé

Niveau	Part des enfants	Se lit comme
Faible	les 50 % les moins à risque	pas de priorité particulière
Moyen	les 30 % suivants	à surveiller
Élevé	les 20 % les plus à risque	à visiter en priorité

Comment régler les coupures

- Partir de ces proportions, puis les **ajuster à la capacité de prise en charge** de l'ONG (si l'équipe ne peut visiter que 10 % des ménages, resserrer le niveau élevé).
- Faire le réglage sur les **probabilités hors apprentissage**, pas sur celles de l'entraînement.
- Un découpage par proportions ou par seuils de probabilité sont deux options : on peut aussi définir "élevé" comme "au moins 1,5 fois la prévalence moyenne".

Vérifications obligatoires

1. La **prévalence réelle monte** de faible à moyen à élevé.
2. Le niveau élevé **capture une part nettement plus grande** des cas que sa taille.
3. Le découpage est **stable** d'un pli à l'autre.
4. Le découpage fonctionne aussi pour les **sous-groupes** (milieu, richesse, ethnie).

Sauvegarder les coupures sous forme de valeurs de probabilité fixes
Pourquoi : en utilisation, un seul enfant ne peut pas être "classé parmi 20 %" sans les autres. Il est comparé à des valeurs fixes trouvées pendant la validation, donc son niveau ne dépend plus des autres enfants saisis ce jour-là.

6.2 Du niveau de l'enfant au niveau du ménage

Un ménage compte 1 à 7 enfants de moins de 5 ans. On regroupe par (grappe, ménage) et on calcule le risque du ménage :

Règle	Avantage	Inconvénient
Maximum des probabilités	Prudent : un seul enfant à risque suffit à déclencher la priorité	Un ménage avec beaucoup d'enfants a plus de chances d'être classé élevé
Moyenne des probabilités	Reflète le risque général du ménage	Peut masquer un enfant très à risque

On compare les deux **au niveau du ménage** (par exemple : quelle part des ménages ayant au moins un enfant touché se retrouve dans le niveau élevé ?), puis on choisit selon l'objectif de l'ONG.

On obtient **deux niveaux par ménage** (un pour le retard de croissance, un pour l'émaciation). Décider si l'on affiche les deux, ou un niveau global égal au plus élevé des deux.

6.3 Expliquer avec SHAP

Ce que fait SHAP : pour une prédiction donnée, il indique **combien chaque réponse a poussé la probabilité vers le haut ou vers le bas**, par rapport à un enfant moyen.

À prévoir

- **Explication globale** : importance moyenne de chaque variable sur tous les enfants, pour comprendre le comportement général du modèle.
- **Explication individuelle** : pour un enfant ou un ménage, les principales raisons du niveau de risque.
- **Regrouper les contributions** des colonnes issues du one-hot en une seule contribution par variable d'origine (afficher "région", pas "région : Savanes" éclatée).
- **Confirmer** avec l'importance par permutation, car deux méthodes d'accord valent mieux qu'une.

Précautions

- SHAP explique **ce que le modèle a utilisé**, pas ce qui **cause** la malnutrition. Présenter les résultats comme des **facteurs associés**.
- Les variables sont corrélées entre elles (région, électricité, toilettes) : l'importance est **partagée** entre variables proches. Ne pas sur-interpréter un classement fin.

6.4 Auditer l'équité

Comparer les performances (AUC, prévalence par niveau) selon le **milieu**, le **quintile de**

richesse et l'**ethnie**.
Pourquoi : vérifier que l'outil n'est pas moins performant pour un groupe, et qu'il ne désavantage pas systématiquement certains ménages. Ces colonnes ne sont **jamais** des entrées du modèle.

6.5 Ce que l'outil final affiche à l'agent

- le **niveau de risque** du ménage (faible, moyen, élevé), pour chaque problème ;
- les **principaux facteurs** qui l'expliquent ;
- un rappel clair : **l'outil classe, il ne diagnostique pas**.

Éviter d'afficher un pourcentage brut si les probabilités ne sont pas calibrées.

---

7. Pièges à éviter

Piège	Conséquence	Parade
Utiliser les z-scores ou les niveaux comme entrées	Fuite de données : le modèle "triche"	Liste de colonnes interdites, contrôle automatique
Découper au hasard sans tenir compte des grappes	Performances gonflées	Validation groupée par grappe
Imputer, encoder ou standardiser avant de découper	Fuite de données	Tout dans un pipeline ajusté sur l'entraînement
Se fier à l'accuracy	Résultat trompeur (surtout émaciation)	AUC, PR-AUC, prévalence par niveau
Sur-régler sur un petit jeu	Validation sur-ajustée	Réglage léger, jeu de test final intact
Sur-échantillonner artificiellement	Fausses probabilités	Pondération, ou sur-échantillonnage dans les plis seulement
Afficher la probabilité brute comme "chance d'être malnutri"	Message trompeur	Calibrer, ou afficher seulement le niveau
Lire SHAP comme des causes	Conclusions fausses	Parler de facteurs associés
Utiliser ethnie ou religion comme entrées	Discrimination, variables sensibles	Colonnes d'audit seulement

Utiliser les prévalences non pondérées pour le pays	Chiffres non représentatifs	Utiliser le poids d'échantillonnage
Trouver un très bon score	Fuite probable	Chercher l'erreur avant de célébrer

---

8. Livrables et ordre d'exécution

Arborescence

```
NutriPulse/
|-- README.md
|-- notebook/
|   |-- nettoyage.ipynb
|   |-- analyse_1_exploration.ipynb
|   |-- analyse_2_modelisation.ipynb
|   |-- interface_gradio.ipynb
|-- modeles/  (modèles, pipelines, coupures, règles ménage)
|-- data/
    |-- raw/      ch.sav, hh.sav, hl.sav  (jamais modifiés)
    |-- clean/    nutripulse_clean.parquet (produit uniquement par le nettoyage)
```

Ordre de travail

#	Étape	Résultat attendu
1	Nettoyage	Un fichier propre, contrôlé, avec les deux cibles
2	Exploration	Compréhension des tendances et des liens, plancher de performance
3	Pipeline et découpage groupé	Prétraitement sans fuite, jeu de test mis de côté
4	Comparaison des modèles (régression logistique, forêt aléatoire, gradient boosting)	Un modèle retenu par cible
5	Probabilités hors apprentissage et calibration	Probabilités fiables
6	Découpage en niveaux de risque	Coupures fixées et vérifiées

7	Regroupement par ménage	Niveau de risque du ménage
8	SHAP et audit d'équité	Explications et vérification d'équité
9	Évaluation finale sur le jeu de test	Performance honnête
10	Sauvegarde des modèles, du pipeline et des coupures	Outil prêt à utiliser
11	Interface Gradio (voir la partie 9)	Démonstration utilisable par le jury

En résumé

> On nettoie les données et on crée deux cibles (**stunt** et **waste**). On explore pour comprendre. On entraîne un modèle par cible pour obtenir une **probabilité**. On **découpe cette probabilité** en trois niveaux de risque selon notre capacité de prise en charge. On regroupe par **ménage**. On explique chaque classement avec **SHAP**. Et on rappelle toujours que l'outil **aide à prioriser**, il ne remplace pas la mesure.

---

9. L'interface Gradio

9.1 Rôle de l'interface

L'interface Gradio est la **première vitrine** du projet. Elle permet à une personne (le jury, un agent de santé, un partenaire) de **voir l'outil fonctionner** : on saisit les réponses d'un enfant, et l'outil renvoie un niveau de risque et les raisons.

- Elle **n'entraîne rien** et **ne recalcule rien** : elle utilise uniquement ce qui a été sauvegardé à la fin de la modélisation.
- Elle vit **dans un notebook** : pas besoin de serveur ni de base de données.
- Elle n'est **pas l'application finale**. Elle montre le trajet complet, de la saisie à l'explication. Une application plus riche pourrait venir ensuite.

9.2 Ce que l'interface charge au démarrage

Tout ce qui a été figé à la fin de la modélisation :

1. Les **deux modèles** (retard de croissance et émaciation), chacun avec son **pipeline** de prétraitement.
2. Les **valeurs de coupure** des trois niveaux (faible, moyen, élevé) pour chaque modèle.
3. La **règle de regroupement par ménage** (niveau le plus élevé ou moyenne).

4. Les **explicateurs SHAP** associés à chaque modèle.

Pourquoi : l'interface doit appliquer **exactement** le même traitement que pendant l'entraînement. Si elle refaisait le prétraitement à sa façon, les résultats seraient faux sans que rien ne le signale.

9.3 Le parcours à l'écran

Étape 1 : la saisie

Le questionnaire est découpé en **trois blocs**, comme les variables du projet :

Bloc	Contenu	Utilisé par
Commun	Âge de l'enfant, région, instruction de la mère, électricité, cuisinière, toilettes	Les deux modèles
Retard de croissance	Sexe, acte de naissance, source d'eau, animaux d'élevage	Modèle retard de croissance
Émaciation	Âge de la personne qui garde l'enfant, taille du ménage, lavage des mains, téléphone	Modèle émaciation

Le type de champ dépend de la variable :

Type de variable	Champ conseillé
Âge, taille du ménage, âge de la personne qui garde l'enfant	Champ numérique avec minimum et maximum
Région, instruction, électricité, cuisinière, toilettes, lavage des mains	Liste déroulante (ou boutons de choix)
Oui/non (acte de naissance, animaux, téléphone, eau)	Boutons de choix ou cases à cocher
Sexe	Boutons de choix

Règles de saisie à respecter :

- **Mêmes modalités que dans le fichier propre.** Les choix proposés à l'écran correspondent aux regroupements faits au nettoyage (par exemple 4 types de toilettes, 4 types de cuisinière, 3 niveaux de lavage des mains).
- **Libellés en langage de terrain.** L'agent voit des mots simples ; l'interface les traduit vers les modalités du modèle.

- **Option "Ne sait pas".** Elle donne une valeur manquante, que le pipeline sait traiter comme à l'entraînement.
- **Contrôles de saisie** : âge entre 0 et 59 mois, taille du ménage plausible (au-delà du plafond utilisé au nettoyage, on applique le même plafond).

Étape 2 : le calcul (invisible pour l'utilisateur)

1. Les réponses sont mises en tableau, avec les **mêmes noms de colonnes** que le fichier propre.
2. Chaque modèle reçoit ses variables et produit une **probabilité**.
3. La probabilité est comparée aux **coupures figées** : faible, moyen ou élevé.
4. Si le ménage compte plusieurs enfants, on applique la **règle de regroupement**, puis on prend le niveau le plus élevé des deux problèmes pour le niveau global.

Étape 3 : l'affichage du résultat

- Le **niveau de risque** du ménage, bien visible, avec un code couleur (vert, orange, rouge).
- Le **niveau pour chaque problème** : retard de croissance et émaciation.
- Les **principaux facteurs** (SHAP), sous forme de graphique et de phrases courtes.
- Un **rappel permanent** : "Cet outil aide à prioriser les visites. Il ne pose pas de diagnostic et ne remplace pas la mesure."

À ne pas afficher telle quelle : la **probabilité brute**, sauf si elle a été calibrée. Sinon elle ne se lit pas comme une "chance d'être malnutri". Le niveau suffit.

9.4 Gérer plusieurs enfants dans un ménage

Un ménage compte de 1 à 7 enfants de moins de 5 ans. L'interface doit donc permettre de :

1. **Ajouter un enfant** à la liste du ménage en cours.
2. Voir un **tableau récapitulatif** : un enfant par ligne, avec son niveau pour chaque problème.
3. Voir en dessous le **niveau du ménage**, calculé avec la règle retenue.
4. **Retirer ou corriger** un enfant saisi par erreur.

Pourquoi : l'objectif du projet est de prioriser des **ménages**, pas seulement des enfants.

9.5 L'explication avec SHAP

- Les explications sont calculées **pour l'enfant saisi**, avec l'explicateur du modèle correspondant.
- Les colonnes encodées sont **regroupées** : on affiche "Région" et non plusieurs

morceaux de région.

- On affiche **trois à cinq facteurs** : ceux qui font monter le risque et ceux qui le font baisser.
- Chaque facteur est écrit en **phrase simple** (par exemple "Pas de toilettes dans le ménage : augmente le risque").
- Formulation à respecter : **facteurs associés au risque**, jamais "causes de la malnutrition".

9.6 Présentation

- Un écran **sobre** : peu de champs visibles à la fois, blocs bien séparés.
- Des **couleurs de niveau** cohérentes avec le reste du projet.
- Des textes **en français simple**, sans vocabulaire technique.
- Un **avertissement toujours visible** (l'outil classe, il ne diagnostique pas).
- Une mise en page **lisible sur téléphone**, car l'usage visé est le terrain.
- Un bouton pour **recommencer** une saisie.

9.7 Ce qu'il faut tester avant une démonstration

Test	Pourquoi
Trois profils types : un enfant très favorisé, un intermédiaire, un très défavorisé	Vérifier que les niveaux sortent dans le bon ordre
Enfant de 0 mois et enfant de 59 mois	Vérifier les bornes
Réponses "ne sait pas"	Vérifier que les manquants ne font pas planter l'outil
Ménage avec plusieurs enfants	Vérifier le regroupement
Mêmes réponses saisies deux fois	Vérifier que le résultat est identique
Comparaison avec le notebook de modélisation	Vérifier qu'un même enfant donne **la même probabilité** dans l'interface et dans le notebook
Temps de réponse	Une démonstration ne doit pas attendre

Le test le plus important est la **comparaison avec le notebook** : si l'interface et la modélisation donnent des résultats différents pour le même enfant, il y a une incohérence de prétraitement à corriger avant toute démonstration.

9.8 Ce que l'interface ne fait pas (et ce que ferait une application)

Dans le notebook (interface Gradio)	Dans une application (si le temps le permet)
Saisie, prédiction, niveau de risque, SHAP	Tout ce qui précède
Aucune donnée conservée	Base de données : identifiant de l'enfant, historique, retour sur une fiche
Aucune carte	Carte des zones avec les niveaux de risque
Un utilisateur à la fois	Tableau de bord, classement des ménages, alertes

L'interface Gradio est donc la **première pierre**. Elle montre que l'idée fonctionne de bout en bout. La carte, la base de données et le suivi relèvent d'une application construite ensuite.

Point de vigilance sur les données : l'interface ne doit **enregistrer aucune donnée personnelle** (pas de nom, pas de localisation précise). Pour une démonstration, tout reste en mémoire le temps de la session.

9.9 Ordre de construction

1. Sauvegarder à la fin de la modélisation : modèles, pipelines, coupures, règle de regroupement, explicateurs.
2. Créer le notebook de l'interface et **charger** ces éléments.
3. Écrire une **fonction de prédiction** qui prend les réponses, applique le pipeline, calcule les probabilités et renvoie les niveaux.
4. Ajouter l'**explication SHAP** pour un enfant.
5. Dessiner l'**écran de saisie** (trois blocs) et l'**écran de résultat**.
6. Ajouter la gestion de **plusieurs enfants** et le **niveau du ménage**.
7. Ajouter l'avertissement, les couleurs et les contrôles de saisie.
8. Faire les **tests** de la partie 9.7.
9. Préparer une **démonstration** avec trois profils types prêts à saisir.