NutriPulse

Nettoyage des données MICS6 Togo 2017

Les choix expliqués, étape par étape

Partie 1 sur 3 : le nettoyage

Document d'accompagnement du notebook notebook/nettoyage.ipynb

Pas d'analyse ici : seulement la préparation propre des données.

Sommaire

1. Ce que fait le nettoyage . . . 3

Les trois fichiers de départ . . . 3

Mini-glossaire . . . 3

2. Le trajet en un coup d'œil . . . 4

3. Les choix, étape par étape . . . 4

Étape 1 - Lire les codes, pas les textes . . . 4

Étape 2 - Identifiants uniques . . . 4

Étape 3 - Colonnes utiles seulement . . . 4

Étape 4 - Assembler les trois fichiers . . . 5

Étape 5 - Retirer les mesures absentes ou douteuses . . . 5

Étape 6 - Créer les deux cibles . . . 5

Étape 7 - Nettoyer les variables . . . 5

Étape 8 - Groupes, poids, audit . . . 5

Étape 9 - Fixer les types . . . 6

Étape 10 - Contrôles automatiques . . . 6

Étape 11 - Exporter et relire . . . 6

4. Les 14 variables d'entrée . . . 7

Communes aux deux modèles (6) . . . 7

Propres au retard de croissance (4) . . . 7

Propres à l'émaciation (4) . . . 8

5. Ce qui est volontairement laissé de côté . . . 9

Opérations non faites au nettoyage . . . 9

Variables jamais utilisées comme entrées . . . 9

6. Les pièges rencontrés dans les données . . . 9

7. Le fichier propre en chiffres . . . 10

8. Organisation du dossier et relance . . . 10

1. Ce que fait le nettoyage

L'enquête MICS6 du Togo (2017) est répartie en **plusieurs gros fichiers bruts**, avec des centaines de colonnes et des codes numériques difficiles à lire. Le nettoyage transforme trois de ces fichiers en **un seul tableau propre** : une ligne par enfant de 0 à 59 mois, des colonnes claires, des types corrects, et les deux variables à prédire (retard de croissance et émaciation).

Le travail est fait dans un notebook, `nettoyage.ipynb`, écrit pour qu'une personne qui découvre le projet puisse suivre chaque décision : pour chaque étape, il explique *ce qu'on fait* et *pourquoi*.

> **Ce que le nettoyage ne fait pas**
>
> Il ne remplace pas les valeurs manquantes, ne transforme pas les catégories en nombres et ne change pas les échelles. Tout cela "apprend" à partir des données : le faire maintenant, sur l'ensemble des enfants, ferait fuiter de l'information du futur test vers l'entraînement. Ce sera fait plus tard, dans la modélisation, uniquement sur la partie d'entraînement.

Principe simple : on ne fait que ce qui est nécessaire. Si une opération n'apporte rien à ce stade, elle n'est pas faite.

Les trois fichiers de départ

- **ch** : un enfant de moins de 5 ans par ligne (5 030 enfants). On y trouve les mesures, les z-scores, l'instruction de la mère et l'acte de naissance.
- **hh** : un ménage par ligne (8 404 ménages). On y trouve l'électricité, la cuisinière, les toilettes, l'eau, le téléphone, les animaux et le nombre de personnes.
- **hl** : une personne par ligne (34 988 personnes). On y trouve le sexe et l'âge de chaque membre du ménage, ce qui permet de retrouver le sexe de l'enfant et l'âge de la personne qui le garde.

Mini-glossaire

- **Grappe** : un petit groupe de ménages enquêtés dans la même zone. Les enfants d'une même grappe se ressemblent.
- **z-score** : une mesure (taille ou poids) comparée à celle d'enfants en bonne santé du même âge. Un z-score de 0 est la moyenne ; plus il est négatif, plus l'enfant est loin sous la moyenne.
- **Retard de croissance (stunt)** : l'enfant est trop petit pour son âge. Problème chronique.
- **Émaciation (waste)** : l'enfant est trop maigre pour sa taille. Problème aigu.
- **Parquet** : un format de fichier qui garde les types des colonnes (catégories, ordre, entiers avec cases vides), contrairement au CSV.

2. Le trajet en un coup d'œil

Le notebook suit onze étapes, toujours dans le même ordre :

1. Lire les fichiers en gardant les codes, et lire le sens des codes avant toute décision.
2. Vérifier que les identifiants ne sont pas en double.
3. Garder seulement les colonnes utiles et leur donner des noms lisibles.
4. Assembler les trois fichiers, sans perdre ni dupliquer un enfant.
5. Retirer les enfants sans mesure ou avec une mesure jugée douteuse.
6. Créer les deux cibles à partir des z-scores de l'OMS.
7. Nettoyer les 14 variables d'entrée une par une.
8. Conserver les groupes, les poids et les colonnes d'audit.
9. Fixer le type de chaque colonne.
10. Lancer des contrôles automatiques qui arrêtent tout en cas d'erreur.
11. Écrire le fichier propre, puis le relire pour vérifier qu'il est identique.

> **Règle d'or**
> Les fichiers bruts ne sont jamais modifiés. Le fichier propre n'est produit que par le notebook : si une règle change, on corrige le notebook, on le relance, et le fichier est régénéré. On ne retouche jamais le fichier propre à la main.

3. Les choix, étape par étape

Étape 1 - Lire les codes, pas les textes

Les fichiers sont lus avec les **codes numériques** (1, 2, 3...) plutôt que les libellés ("Oui", "Non"). C'est volontaire : on veut voir les codes spéciaux comme 7, 8, 9, 96 ou 97 pour décider nous-mêmes, variable par variable, s'ils signifient "valeur manquante" ou "vraie réponse".

Avant chaque décision, on affiche le sens de chaque code. Un même code n'a pas le même sens partout : 97 est "incohérent" pour la taille du ménage, mais "pas de repas préparé" (une vraie réponse) pour le type de cuisinière. On ne devine jamais.

Étape 2 - Identifiants uniques

Un enfant se reconnaît par (grappe, ménage, ligne de l'enfant), un ménage par (grappe, ménage), une personne par (grappe, ménage, ligne). On vérifie qu'aucun doublon n'existe : c'est la condition pour que l'assemblage des fichiers soit fiable.

Étape 3 - Colonnes utiles seulement

Le fichier des enfants compte 467 colonnes. On n'en garde que 17, avec des noms courts en minuscules (par exemple `HC8` devient `electricite`). On renomme **avant** d'assembler, car

certaines colonnes portent le même nom dans deux fichiers, ce qui créerait des confusions.

Étape 4 - Assembler les trois fichiers

On part des enfants et on leur ajoute le sexe (cherché dans hl par le numéro de ligne), les caractéristiques du ménage (cherchées dans hh), et l'âge de la personne qui garde l'enfant (cherché dans hl avec le numéro de ligne du gardien). Toutes les jointures conservent tous les enfants : on préfère une case vide à un enfant perdu en silence.

Résultat : 5 030 enfants avant, 5 030 après, aucun doublon. Le sexe et la région, déjà présents dans le fichier des enfants, servent de copies de contrôle et concordent à 100 % avec ce que l'assemblage a apporté.

Étape 5 - Retirer les mesures absentes ou douteuses

Les cibles se calculent à partir des mesures : sans mesure fiable, pas de cible. On retire :

- **88 enfants sans mesure** (absents, refus...) ;
- **42 enfants avec une mesure jugée implausible** par l'enquête (drapeaux de plausibilité). Ces mesures sont codées avec la valeur factice 99.99, qui fausserait tout calcul.

Il reste **4 900 enfants**. On retire un enfant dès que l'une de ses deux mesures pose problème, afin de garder le même groupe d'enfants pour les deux modèles.

Étape 6 - Créer les deux cibles

On utilise les z-scores de l'OMS (jamais les anciens z-scores NCHS). Sous -2, l'enfant est touché ; entre -3 et -2, c'est modéré ; sous -3, c'est sévère.

- `stunt` et `waste` valent 1 si l'enfant est touché, 0 sinon : ce sont les deux réponses que les modèles apprendront à prédire.
- `stunt_niveau` et `waste_niveau` (0 normal, 1 modéré, 2 sévère) servent seulement à décrire la réalité, jamais à entraîner.

> **Pourquoi les z-scores ne servent jamais d'entrée**
>
> Le z-score est la réponse elle-même, calculée à partir de la taille et du poids. L'utiliser pour prédire la malnutrition reviendrait à donner la correction à l'élève : le modèle aurait de très bons résultats, mais ils ne voudraient rien dire.

Étape 7 - Nettoyer les variables

Trois règles s'appliquent partout : les codes "incohérent", "ne sait pas" et "non réponse" deviennent des cases vides ; les codes trop détaillés sont regroupés pour éviter de minuscules catégories qui ne feraient que du bruit ; les questions oui/non deviennent 1 ou 0. Le détail variable par variable est donné dans la section 4.

Étape 8 - Groupes, poids, audit

- **La grappe** est conservée : plus tard, les données seront découpées par grappe entière. Si on séparait les enfants au hasard, des enfants presque identiques se retrouveraient à la fois dans l'entraînement et le test, et les performances seraient gonflées.
- **L'identifiant du ménage** permettra de regrouper à la fin les enfants d'un même ménage.
- **Le poids d'enquête** servira uniquement pour des chiffres nationaux, jamais comme entrée.
- **Milieu, quintile de richesse et ethnie** sont gardés en colonnes d'audit pour vérifier plus tard l'équité de l'outil. Ils ne seront jamais des entrées, l'ethnie étant une variable sensible.

Étape 9 - Fixer les types

Dans MICS, presque tout est stocké en nombres, même ce qui n'est pas une quantité. Un code n'est pas un nombre : si la région restait numérique, un modèle croirait que la région 4 vaut "deux fois" la région 2. Chaque colonne reçoit donc le type qui correspond à sa nature :

- **catégorie sans ordre** : région, type de cuisinière, milieu, ethnie ;
- **catégorie ordonnée** (ordre écrit explicitement) : instruction de la mère, électricité, toilettes, lavage des mains, quintile de richesse ;
- **entier 0/1** pour les oui/non, avec case vide possible quand il reste des valeurs manquantes ;
- **entier** pour l'âge de l'enfant, l'âge du gardien et la taille du ménage.

Étape 10 - Contrôles automatiques

Si l'un des contrôles échoue, le notebook s'arrête avec un message clair. On vérifie notamment :

- le nombre de lignes et l'absence de doublons ;
- que les variables 0/1 ne contiennent que 0 ou 1 ;
- que les **cases vides sont exactement celles attendues**, recalculées à partir des codes bruts ;
- qu'aucune colonne interdite (z-scores, cibles, poids, audit, identifiants) ne se trouve parmi les entrées ;
- que les cibles sont cohérentes avec les niveaux et les z-scores ;
- que l'âge reste entre 0 et 59 mois et que la taille du ménage ne dépasse pas le plafond.

Étape 11 - Exporter et relire

Le fichier est écrit au format **parquet**, puis relu et comparé à l'original : toute différence, même de type, arrête le notebook. Un petit fichier JSON sauvegarde aussi le plafond de la taille du ménage et la liste des variables par modèle, dont l'interface finale aura besoin.

4. Les 14 variables d'entrée

Six variables sont communes aux deux modèles, quatre sont propres au retard de croissance et quatre à l'émaciation. Chacune est décrite avec la règle appliquée.

Communes aux deux modèles (6)

age_mois - âge de l'enfant en mois

Aucun code spécial. On vérifie seulement que les valeurs sont entre 0 et 59.

region - région de résidence

Les 7 numéros sont remplacés par les noms : Maritime, Plateaux, Centrale, Kara, Savanes, Lomé Commune, Golfe Urbain. Variable nominale, sans ordre.

edu_mere - instruction de la mère

Trois niveaux ordonnés : Aucune, Primaire, Secondaire ou plus. "Ne sait pas" devient une case vide (1 enfant).

electricite - électricité dans le ménage

Trois niveaux ordonnés : Non, Hors réseau (générateur, système isolé), Réseau. "Incohérent" aurait été une case vide, mais ne se présente pas dans l'échantillon.

cuisiniere - type de cuisinière

Onze codes regroupés en quatre modalités : Électricité, gaz ou liquide ; Combustible solide (cuisinière) ; Feu ouvert ; Pas de repas préparé. Le code 97 est ici une **vraie réponse**, on le garde. "Autre" (code 96) est trop flou : case vide (2 enfants). La dernière modalité ne concerne que 7 enfants : on ne la fusionne pas à ce stade, car décider quoi regrouper dépend de l'apprentissage.

toilettes - type de toilettes

Quatorze codes regroupés en quatre modalités ordonnées, de la moins à la plus favorable : Aucune ; Non améliorée (latrine sans dalle, seau, toilettes suspendues, chasse d'eau vers l'air libre ou un lieu inconnu) ; Latrine améliorée (ventilée, avec dalle, compostage, chasse d'eau vers latrine) ; Chasse d'eau (égout ou fosse septique). "Autre" et "incohérent" : cases vides (13 enfants).

Propres au retard de croissance (4)

sexe_f - sexe de l'enfant

1 si fille, 0 si garçon. Le nom rappelle ce que veut dire le 1. Le sexe vient de hl, retrouvé par le numéro de ligne de l'enfant.

acte_naissance - acte de naissance

"Oui, vu" et "oui, pas vu" sont regroupés en 1 ; "non" vaut 0 ; "ne sait pas" devient une case vide (12 enfants).

eau_amelioree - source d'eau de boisson

Seize sources ramenées à une seule question : la source est-elle améliorée (1) ou non (0) ? Sont améliorés : robinets, forage, puits protégé, source protégée, eau de pluie, camion-citerne, charrette avec citerne, eau en bouteille ou en sachet. Ne sont pas améliorés : puits non protégé, source non protégée, eau de surface. "Autre" et "incohérent" : cases vides (9 enfants).

animaux - animaux d'élevage

Oui = 1, non = 0.

Propres à l'émaciation (4)

age_gardien - âge de la personne qui garde l'enfant

Cherché dans hl via le numéro de ligne du gardien. Le code 97 deviendrait un âge de 97 ans : il est remplacé par une case vide (aucun cas dans l'échantillon). Les âges vont de 14 à 75 ans, ce qui est plausible : aucune correction n'est faite sur des valeurs réalistes.

taille_menage - nombre de personnes du ménage

Plafonnée au 99e percentile, c'est-à-dire à **19 personnes** : 19 enfants vivent dans un ménage plus grand (le maximum était 23). Cela évite que quelques très grands ménages pèsent trop lourd. Le plafond est sauvegardé pour que l'interface finale applique la même règle.

lavage_mains - lieu de lavage des mains observé

Trois modalités ordonnées : Aucun lieu ou refus ; Ustensile mobile (seau, jarre, bouilloire) ; Lieu fixe (lavabo ou robinet, dans le logement ou la parcelle). Le refus est fusionné avec "aucun lieu", car dans les deux cas on ne peut pas affirmer qu'un dispositif existe.

telephone - téléphone portable dans le ménage

Oui = 1, non = 0.

5. Ce qui est volontairement laissé de côté

Opérations non faites au nettoyage

- **Remplir les cases vides** : on laisse les trous visibles. Le choix de la valeur de remplacement se calcule sur l'entraînement seulement, plus tard.
- **Transformer les catégories en nombres** : même raison, ce sera fait dans le pipeline de modélisation.
- **Changer les échelles** : inutile ici, et seuls certains modèles en ont besoin.
- **Supprimer des enfants à cause d'une case vide** : il y en a très peu (au plus 13 cases vides par variable sur 4 900 enfants) et le pipeline saura les traiter.
- **Corriger des valeurs réalistes** : par exemple les âges de gardien, qui sont plausibles.

Variables jamais utilisées comme entrées

- **Fuites** : tout ce qui vient des mesures (poids, taille, z-scores, IMC, drapeaux).
- **Sensibles** : ethnie et religion. L'ethnie reste seulement en colonne d'audit.
- **Redondantes** : indice de richesse (calculé après coup), milieu urbain ou rural (déjà couvert par la région), type d'éclairage (déjà couvert par l'électricité), matériaux du logement.
- **Trop peu renseignées** : alimentation, vaccination, handicap, moustiquaires (moins de 90 % des enfants concernés).
- **Symptômes récents** : diarrhée, fièvre, toux. Un enfant malnutri tombe plus souvent malade : la cause et la conséquence seraient mélangées.

6. Les pièges rencontrés dans les données

> **Les libellés de l'ethnie se contredisent entre deux fichiers**
>
> Les codes sont les mêmes dans le fichier des enfants et celui des ménages, mais pas leurs libellés : le code 3 est "Paragourma" dans l'un et "Akposso" dans l'autre, et c'est l'inverse pour le code 5. On a tranché avec la géographie : 70 % des enfants du code 5 vivent dans les Savanes, région des Para-Gourma, et 61 % de ceux du code 3 vivent dans les Plateaux, région des Akposso. Les libellés du fichier des ménages sont donc les bons, et ceux du fichier des enfants sont inversés pour ces deux codes. Le notebook garde les codes du fichier des enfants avec les bons libellés.

- **Le code 97** n'a pas le même sens selon la variable (incohérent ou vraie réponse).
- **La valeur 99.99** est une valeur factice placée sur les mesures jugées implausibles. Le notebook vérifie qu'elle ne reste nulle part après le filtrage.
- **Les ménages sans interview complète** ont des colonnes vides dans le fichier des ménages (488 lignes), mais aucun enfant de l'échantillon n'en vient : tous ont leurs informations de ménage.

- **Un identifiant d'enfant n'est jamais un numéro seul** : le numéro de ligne se répète d'un ménage à l'autre, il faut toujours l'associer à la grappe et au ménage.

7. Le fichier propre en chiffres

4 900 enfants de 0 à 59 mois, répartis dans **419 grappes** et **3 371 ménages** (de 1 à 7 enfants par ménage), sur **28 colonnes** : 4 identifiants, 2 cibles, 4 colonnes de description, 14 variables d'entrée, 1 poids, 3 colonnes d'audit.

Vérification de la construction des cibles (simple contrôle, ce n'est pas une analyse) :

- Retard de croissance : 3 708 enfants normaux, 838 modérés, 354 sévères.
- Émaciation : 4 618 enfants normaux, 225 modérés, 57 sévères.

Cases vides restantes : 13 pour les toilettes, 12 pour l'acte de naissance, 9 pour l'eau, 2 pour la cuisinière et 1 pour l'instruction de la mère. Les 9 autres variables d'entrée sont complètes.

> **Ce que le fichier propre garantit**
>
> Aucun doublon, aucune valeur factice, aucun code spécial laissé comme un nombre, des types corrects et conservés à la relecture, et des cases vides qui correspondent exactement aux codes décidés comme manquants.

8. Organisation du dossier et relance

Le zip contient les données, le notebook et les documents :

```
NutriPulse/
|-- README.md
|-- requirements.txt
|-- data/
|   |-- raw/      ch.sav, hh.sav, hl.sav  (jamais modifiés)
|   |-- clean/    nutripulse_clean.parquet
|                 parametres_nettoyage.json
|-- notebook/
|   |-- nettoyage.ipynb
|-- docs/
    |-- NutriPulse_Choix_de_nettoyage.pdf  (ce document)
    |-- NutriPulse_Architecture.pdf        (démarche générale)
```

Pour relancer le nettoyage : installer les bibliothèques de `requirements.txt`, ouvrir `notebook/nettoyage.ipynb` et tout exécuter. Le fichier propre est alors régénéré à l'identique. Le notebook fonctionne que l'on parte du dossier `notebook` ou de la racine du projet.

Étape suivante : l'analyse exploratoire (`analyse_1_exploration.ipynb`), qui ne lira que le fichier `nutripulse_clean.parquet`.